Università degli studi di Salerno

Progetto di Strumenti Formali per la Bioinformatica

Inferenza Causale Controfattuale per la Valutazione della Robot-Enhanced Therapy nel Progetto DREAM

Autore: Malafronte Sabato (matricola 0522501833)

Proff. Rocco Zaccagnino, Rosalba Zizza, Cleila De Felice

Tutor: dott. Alessia Ture

Anno Accademico 2025/2026

Indice

1 Introduzione **3**
1.1 Stato dell'Arte . . . 3
1.2 Utilizzo del Dataset DREAM in letteratura . . . 3
1.3 Fondamenti di Inferenza Causale . . . 4
1.3.1 Exchangeability (Scambiabilità Condizionale) . . . 4
1.3.2 Positivity (Supporto Comune) . . . 4
1.3.3 SUTVA (Stable Unit Treatment Value Assumption) . . . 4
1.3.4 Stimare l'Ate: definizione e limiti . . . 5

2 Il dataset DREAM **6**
2.1 Origine e reperimento dei dati . . . 6
2.2 Struttura del dataset . . . 6

3 Metodologia **9**
3.1 Analisi Statistica preliminari . . . 9
3.2 Stima del Propensity Score . . . 11
3.2.1 Configurazione del Modello Logit . . . 11
3.2.2 Validazione del Bilanciamento . . . 12
3.3 Definizione dell'Outcome Proxy: AttentionScore . . . 13
3.3.1 Allineamento Vettoriale e Cosine Similarity . . . 13
3.3.2 Interpretazione del proxy AttentionScore . . . 14
3.3.3 Analisi descrittiva dell'AttentionScore . . . 15
3.3.4 Test di significatività statistica: Welch t-test . . . 16
3.4 Limiti dei Modelli Classici e Necessità del Causal Deep Learning 16
3.4.1 L'architettura DragonNet . . . 16
3.4.2 Il Modello BCAUSS . . . 17
3.4.3 Protocollo di Training e Strategia di Validazione . . . 17

4 Risultati e discussioni **18**
4.1 Confronto delle Stime ATE . . . 18
4.2 Interpretazione dei Risultati . . . 18
4.2.1 Analisi dell'Effetto Medio e Variabilità Individuale . . . 19
4.2.2 Resilienza ai Fattori Confondenti . . . 19

5 Conclusioni e Sviluppi Futuri **20**
5.1 Sintesi del Lavoro e Metodologia . . . 20
5.2 Considerazioni sui Risultati . . . 20
5.3 Limiti e Prospettive Future . . . 21

Riferimenti bibliografici **22**

Elenco delle figure

1 Architettura gerarchica dei dati all'interno di una sessione di terapia nel Dataset DREAM. 7
2 Distribuzione dei partecipanti per condizione di trattamento nel Dataset DREAM. 9
3 Analisi della densità di probabilità per le covariate di baseline. La sovrapposizione tra le curve RET (rosso) e SHT (blu) indica un corretto bilanciamento del campione per età (a sinistra) e punteggio ADOS (a destra). 10
4 Distribuzione dei partecipanti genere nei due gruppi di trattamento nel Dataset DREAM. 10
5 Confronto delle medie delle sessioni completate per gruppo. Le barre di errore indicano la deviazione standard (σ). 11
6 Distribuzione dei Propensity Score calcolato sulle sessioni terapeutiche valide. 13
7 Distribuzione dell'outcome proxy AttentionScore per condizione di trattamento nel Dataset DREAM. 15
8 Distribuzione dell'ATE stimato per i modelli DragonNet e BCAUSS su 10 run indipendenti. La linea tratteggiata indica lo zero (assenza di effetto). 19

1 Introduzione

L'autismo (ASD - Autism Spectrum Disorder) è un disturbo neuroevolutivo caratterizzato da deficit persistenti nella comunicazione sociale e nell'interazione, associati a pattern di comportamento ripetitivi. Negli ultimi anni, la ricerca bioinformatica e robotica ha esplorato nuove frontiere terapeutiche, tra cui la **Robot-Enhanced Therapy (RET)**. L'obiettivo del presente studio è valutare, attraverso l'inferenza causale e modelli di Deep Learning, l'efficacia del trattamento robotico rispetto alla terapia classica **(Standard Human Treatment - SHT)** nel migliorare i livelli di attenzione dei pazienti.

1.1 Stato dell'Arte

L'integrazione di sistemi robotici nella terapia del Disturbo dello Spettro Autistico ha mostrato potenzialità significative nel migliorare le abilità sociali dei bambini. Storicamente, tali interventi si sono basati sul paradigma *Wizard of Oz* (WoZ), in cui un operatore umano controlla il robot da remoto. Tuttavia, la ricerca recente sottolinea la necessità di evolvere verso sistemi di autonomia supervisionata [1]. Questo passaggio non solo riduce il carico cognitivo per il terapeuta, ma garantisce una maggiore coerenza e ripetibilità del protocollo terapeutico, elementi fondamentali per il successo dei trattamenti basati sull'analisi applicata del comportamento (ABA - Applied Behavior Analysis).

1.2 Utilizzo del Dataset DREAM in letteratura

Il dataset **DREAM** (*Development of Robot-Enhanced therapy for children with Autism spectrum disorders*) costituisce una risorsa pionieristica per la comunità scientifica. Gli studi condotti su questo dataset hanno validato diversi pilastri della Robot-Enhanced Therapy (RET):

- **Architettura RET:** Esteban et al. [1] descrivono lo sviluppo di un sistema di Robot-Enhanced Therapy (RET) basato su un'autonomia supervisionata. I ricercatori hanno implementato compiti di apprendimento strutturati secondo il formato Discrete Trial (tipico dell'approccio ABA), dimostrando come l'integrazione di sensori e robot possa fornire un supporto costante e oggettivo nella terapia.
- **Validazione Clinica:** Cao et al. [2] hanno dimostrato che il sistema RET, basato su protocolli di intervento comportamentale strutturati, è in grado di indurre nei bambini con ASD risposte sociali e miglioramenti nelle abilità (come imitazione e turn-taking) con un'efficacia paragonabile a quella della terapia standard (SHT), favorendo al contempo un maggiore coinvolgimento emotivo.
- **Sensing e Analisi comportamentale:** Lo studio condotto da Cai et al. [3] ha dimostrato l'efficacia di un sistema di sensing multi-modale (basato su Kinect e telecamere RGB) nell'estrarre automaticamente caratteristiche biometriche quali la posa del corpo, le espressioni facciali e lo sguardo.

Tale tecnologia permette di mappare i comportamenti dei bambini con ASD in classi definite dai clinici, facilitando una valutazione oggettiva e digitalizzata dei progressi durante le sessioni terapeutiche.

1.3 Fondamenti di Inferenza Causale

L'inferenza causale rappresenta oggi il pilastro della ricerca empirica, segnando il passaggio dalla semplice associazione statistica alla determinazione di relazioni causa-effetto. Come evidenziato in letteratura, tale transizione richiede assunzioni teoriche e metodologiche rigorose per evitare di attribuire valenza causale a relazioni puramente descrittive. Il paradigma di riferimento è l'approccio controfattuale, che mira a stimare l'effetto di un trattamento confrontando l'outcome osservato con quello che si sarebbe verificato in assenza di intervento. Questo modello poggia su assunzioni fondamentali quali l'exchangeability, la positivity e la SUTVA [4].

1.3.1 Exchangeability (Scambiabilità Condizionale)

L'assunzione di scambiabilità (o *ignorability*) è il pilastro fondamentale che permette di interpretare un'associazione statistica come una relazione causale. Formalmente, si assume che gli outcome potenziali siano indipendenti dall'effettiva assegnazione al trattamento:

$$(Y^1, Y^0) \perp Z \mid X$$

In termini concettuali, ciò implica che il gruppo dei trattati (RET) e il gruppo di controllo (SHT) siano **confrontabili** e **sostituibili**: a parità di caratterisriche (X), l'assegnazione alla terapia robotica (Z) non dipende dalla condizione clinica. Se avessimo scambiato i due gruppi all'inizio dello studio, somministrando RET a chi ha ricevuto SHT e viceversa, avremmo osservato esattamente gli stessi risultati medi.

1.3.2 Positivity (Supporto Comune)

L'assunzione di positività richiede che, per ogni combinazione di covariate X, vi sia una probabilità non nulla di ricevere ciascun trattamento:

$$0 < P(Z = z \mid X = x) < 1, \quad \forall x \in \mathcal{X}$$

In termini pratici, ciò garantisce che debbano esistere sottogruppi di pazienti definiti dalle caratteristiche di baseline (es. una specifica fascia d'età) che abbiano ricevuto esclusivamente uno dei due interventi.

1.3.3 SUTVA (Stable Unit Treatment Value Assumption)

La SUTVA implica che l'outcome di un individuo non sia influenzato dal trattamento ricevuto da altri soggetti (*assenza di interferenza*) e che non vi siano versioni differenti dello stesso trattamento (*consistenza*).

$$Y_i(z_1, z_2, \ldots, z_n) = Y_i(z_i)$$

1.3.4 Stimare l'Ate: definizione e limiti

L'obiettivo principale del presente lavoro è la stima dell'**Average Treatment Effect (ATE)**, definito formalmente come:

$$ATE = E[Y(1) - Y(0)] \tag{1}$$

dove $Y(1)$ rappresenta l'outcome potenziale sotto trattamento (RET) e $Y(0)$ l'outcome potenziale sotto controllo (SHT). Tuttavia, nella realtà osservazionale (come nel dataset DREAM), ci scontriamo con il **Problema Fondamentale dell'Inferenza Causale**: non possiamo mai osservare contemporaneamente $Y(1)$ e $Y(0)$ per lo stesso bambino.

Un'altra sfida importante risiede nel fatto che, in contesti clinici osservazionali, l'assegnazione al trattamento non è perfettamente casuale. Variabili confondenti (*confounders*) come l'età del bambino, il genere o la severità della diagnosi (punteggio ADOS) possono influenzare sia la probabilità di ricevere il trattamento sia l'outcome finale. I modelli classici di regressione spesso falliscono nel catturare relazioni non lineari complesse in presenza di bias di selezione, rendendo necessario l'impiego di architetture di Deep Learning dedicate proprio alla stima dell'ATE.

2 Il dataset DREAM

2.1 Origine e reperimento dei dati

Il dataset utilizzato in questo studio deriva dal progetto europeo *DREAM (Development of Robot-Enhanced therapy for children with Autism spectrum disorders)*. I dati sono stati reperiti tramite il portale ufficiale *Svensk nationell datatjänst* (`https://researchdata.se/en/catalogue/dataset/snd1156-1/1`).

È opportuno segnalare una discrepanza numerica riscontrata nella letteratura di riferimento riguardo all'entità del dataset:

- Alcune fonti citano il coinvolgimento di 76 bambini e oltre 4000 sessioni di terapia.
- Altre fonti riportano circa 3500 sessioni.

Ai fini della presente ricerca, facciamo riferimento esclusivamente alla release ufficiale scaricata dal link sopra citato. Coerentemente con la documentazione tecnica che accompagna tale versione, il nostro studio si basa su un campione di **61 bambini** per un totale di **3121 sessioni** di terapia.

2.2 Struttura del dataset

La base dati è organizzata in file *JavaScript Object Notation* (JSON), che aggregano i flussi informativi provenienti da un setup multi-sensoriale sincronizzato. Questa architettura permette di mappare l'interazione tra il bambino e l'agente (robotico o umano) attraverso diverse dimensioni cinematiche e comportamentali.

- **Sistemi RGB-D (Microsoft Kinect):** Utilizzati per l'estrazione delle coordinate spaziali dello scheletro 3D e per la modellazione dell'orientamento del capo nello spazio tridimensionale.
- **Sensori RGB:** Dedicati all'analisi delle espressioni facciali e alla stima dei vettori di sguardo (*eye-gaze*).

```
{
    "$id": "User 37_18_Intervention 2_20171102_123242.369000.json",
    "$schema": "https://raw.githubusercontent.com/dream2020/data/mas
ter/specification/dream.1.1.json",
    "ados": {
        "preTest": {
            "communication": 2,
            "interaction": 5,
            "module": 1.0,
            "play": 1,
            "protocol": "ADOS-G",
            "socialCommunicationQuestionnaire": 23,
            "stereotype": 0,
            "total": 7
        }
    },
    "condition": "RET",
    "date": "2017-11-02T12:32:42.369000",
    "eye_gaze": {"rx": [],"ry": [],"rz": []},
    "frame_rate": 25.1,
    "head_gaze": {"rx": [],"ry": [],"rz": []},
    "participant": {"ageInMonths": 47,"gender": "male","id": 37},
    "skeleton": {
        "elbow_left": {"confidence": [],"x": [],"y": [],"z": []},
        "elbow_right": {"confidence": [],"x": [],"y": [],"z": []},
        "hand_left": {"confidence": [],"x": [],"y": [],"z": []},
        "hand_right": {"confidence": [],"x": [],"y": [],"z": []},
        "head": {"confidence": [],"x": [],"y": [],"z": []},
        "sholder_center": {"confidence": [],"x": [],"y": [],"z":
[]},
        "sholder_left": {"confidence": [],"x": [],"y": [],"z": []},
        "sholder_right": {"confidence": [],"x": [],"y": [],"z": []},
        "wrist_left": {"confidence": [],"x": [],"y": [],"z": []},
        "wrist_right": {"confidence": [],"x": [],"y": [],"z": []}
    },
    "task": "TT"
}
```


Figura 1: Architettura gerarchica dei dati all'interno di una sessione di terapia nel Dataset DREAM.

Più nello specifico, come illustrato nella Figura 1, ogni sessione di terapia è strutturata gerarchicamente:

- **Metadata:** Identificativo univoco del soggetto, il timestamp e la *condition* (RET/SHT), che rappresenta la nostra variabile di trattamento T.
- **Skeleton:** Fornisce la scomposizione geometrica dei movimenti corporei. Per ogni giunto articolare vengono registrate le coordinate (x, y, z) lungo l'intero asse temporale della sessione.
- **Gaze:** Rappresenta la componente chiave per la valutazione del comportamento visivo. Contiene i vettori `eye_gaze` (direzione degli occhi) e `head_gaze` (orientamento del volto), le cui componenti (rx, ry, rz) permettono di quantificare il grado di focus del bambino verso il target terapeutico.

L'integrazione di questi stream di dati permette di derivare un **indice sintetico di engagement visivo**, utilizzato come variabile target per misurare l'efficacia del trattamento.

A completamento dei dati dinamici, il dataset associa a ciascuno dei 61 soggetti un profilo clinico e demografico statico, che costituisce l'insieme delle covariate X fondamentali per il bilanciamento dei modelli:

- **Parametri Demografici:** Età cronologica (espressa in mesi) e genere.
- **Profilo Funzionale:** Livello di severità della sintomatologia misurato tramite scala *ADOS*.

3 Metodologia

L'obiettivo di questo progetto è stimare l'effetto medio del trattamento della terapia robotica (RET) rispetto a quella umana (SHT) sull'outcome comportamentale *AttentionScore*. Data la natura osservazionale del dataset DREAM, la metodologia è stata strutturata per mitigare il bias di selezione e garantire la robustezza statistica attraverso l'integrazione di modelli classici e architetture di *Causal Deep Learning*.

3.1 Analisi Statistica preliminari

Il dataset finale comprende 61 soggetti. Per verificare l'assunzione di *Exchangeability* (scambiabilità), è stata condotta un'analisi di bilanciamento sulle covariate di baseline: età in mesi, punteggio ADOS pre-test e genere.

- **Distribuzione del Trattamento:** Il campione è bilanciato, con 30 bambini assegnati alla condizione RET e 31 alla condizione SHT.

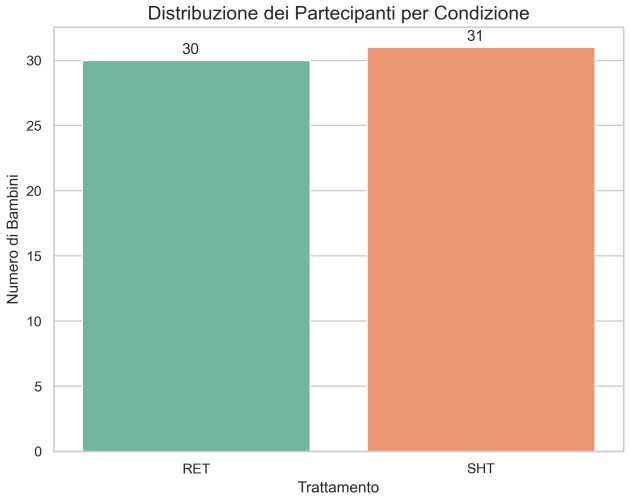

Figura 2: Distribuzione dei partecipanti per condizione di trattamento nel Dataset DREAM.

- **Equità delle Covariate:** Le medie di base non mostrano discrepanze critiche: l'età media è di 52.50 mesi per il gruppo RET e 53.26 per il gruppo SHT; il punteggio ADOS medio è di 13.83 per RET e 14.52 per SHT.

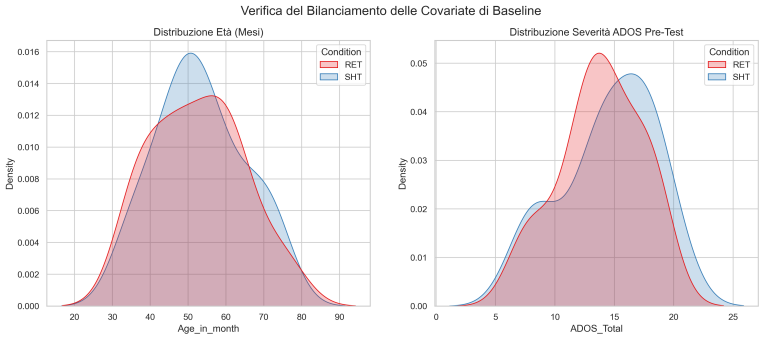

Figura 3: Analisi della densità di probabilità per le covariate di baseline. La sovrapposizione tra le curve RET (rosso) e SHT (blu) indica un corretto bilanciamento del campione per età (a sinistra) e punteggio ADOS (a destra).

- **Bilanciamento per genere:** Anche in questo caso non si verificano discrepanze notevoli: la percentuali di bambini di genere maschile è dell'$86,67\%$ in RET e dell'$83,87\%$ in SHT.

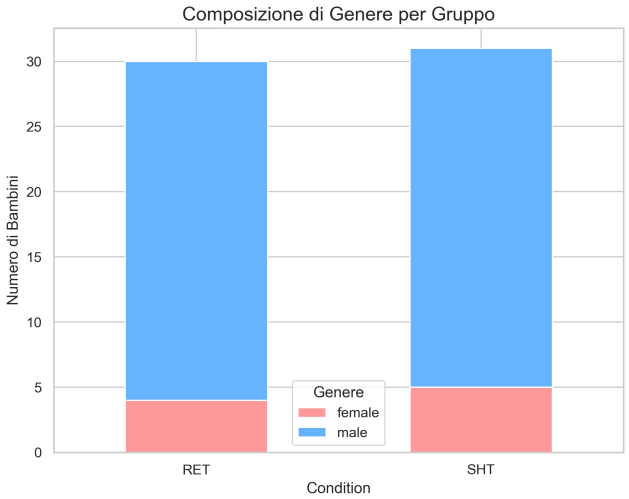

Figura 4: Distribuzione dei partecipanti genere nei due gruppi di trattamento nel Dataset DREAM.

- **Analisi Quantitativa delle Sessioni**

  L'analisi del volume delle sessioni è stata condotta per verificare l'omogeneità dell'esposizione al trattamento tra i due gruppi sperimentali. I risultati mostrano una media complessiva di **51.16** sessioni per partecipante.

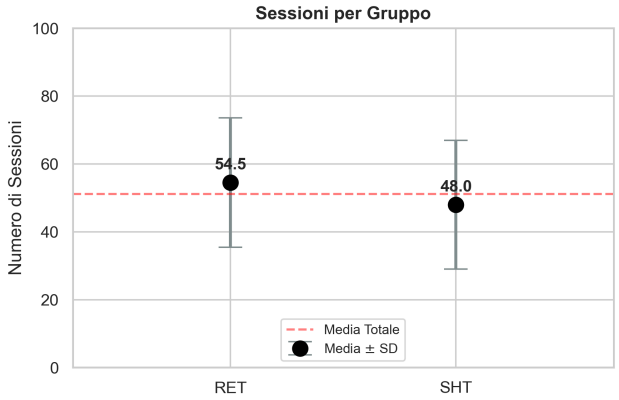

Figura 5: Confronto delle medie delle sessioni completate per gruppo. Le barre di errore indicano la deviazione standard (σ).

Come dettagliato in Figura 5, il gruppo **RET** ha registrato una media di 54.47 sessioni ($\sigma = 19.06$), mentre il gruppo **SHT** si attesta su 47.97 sessioni ($\sigma = 18.93$). La stabilità della deviazione standard tra i due gruppi conferma un comportamento partecipativo coerente, garantendo che l'inferenza causale successiva non sia distorta da una marcata differenza nel dosaggio terapeutico.

3.2 Stima del Propensity Score

Nell'ambito del progetto, la stima del *Propensity Score* è stata utilizzata come strumento di diagnostica per verificare l'assenza di bias di selezione nel dataset DREAM. L'obiettivo è confermare che l'assegnazione dei soggetti al gruppo sperimentale (RET) o di controllo (SHT) sia indipendente dalle variabili anagrafiche e cliniche di baseline.

3.2.1 Configurazione del Modello Logit

È stata implementata una regressione logistica definendo la condizione di trattamento come variabile target. Il modello ha utilizzato le seguenti covariate come predittori:

- **Age_in_month**: Età cronologica per bilanciare lo sviluppo evolutivo.

- **ADOS_Total**: Indice di gravità clinica pre-test.
- **is_male**: Variabile dummy per il bilanciamento di genere.

I parametri stimati dal modello sono riportati nella Tabella 1.

Feature	**Coefficiente**	**Std. Error**	**z-value**	**P> |z|**
Intercept	0.7448	1.695	0.439	0.660
Age (months)	-0.0043	0.022	-0.190	0.849
ADOS Total	-0.0523	0.072	-0.731	0.465
Gender (M)	0.2223	0.731	0.304	0.761

Tabella 1: Output della regressione logistica per la probabilità di trattamento.

3.2.2 Validazione del Bilanciamento

L'analisi dei risultati permette di validare il dataset secondo tre criteri fondamentali per lo sviluppo del modello causale:

1. **Neutralità delle Feature ($P > 0.05$):** Nessuna variabile di baseline mostra un impatto statisticamente significativo sull'assegnazione del trattamento. L'alto valore di p per l'ADOS (0.465) e l'Età (0.849) conferma che i due gruppi RET e SHT sono composti da soggetti sovrapponibili.
2. **Indice di Randomizzazione (Pseudo-R^2):** Il valore ottenuto (0.0081) indica che meno dell'1% della varianza nell'assegnazione è spiegato dalle caratteristiche osservate. Tecnicamente, ciò dimostra che il sistema di assegnazione si comporta in modo quasi-casuale, eliminando la necessità di correzioni drastiche per variabili confondenti.
3. **Verifica del Supporto Comune:** Il *LLR p-value* di 0.8766 conferma l'ipotesi nulla di un modello nullo, garantendo la **Positività** del campione (Figura 6).

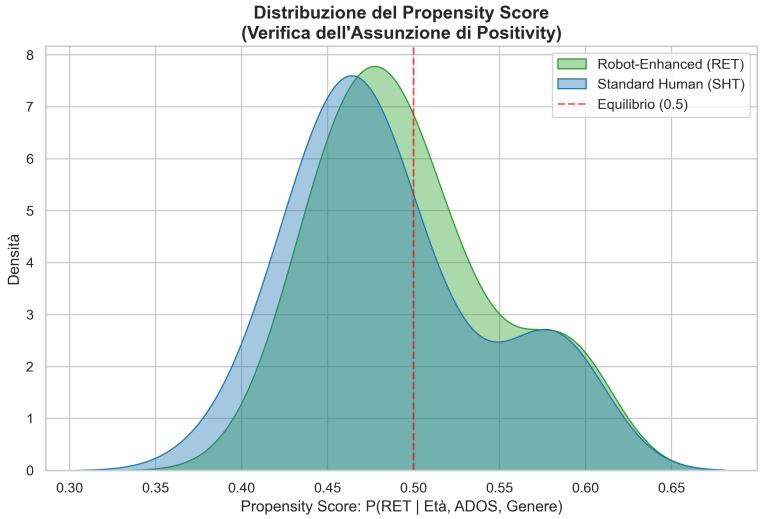

Figura 6: Distribuzione dei Propensity Score calcolato sulle sessioni terapeutiche valide.

3.3 Definizione dell'Outcome Proxy: AttentionScore

È importante sottolineare che la release pubblica del dataset DREAM **non** include i punteggi ADOS relativi alla fase di post-test. Di conseguenza, non è possibile effettuare una valutazione diretta del miglioramento clinico a lungo termine tramite scale diagnostiche standardizzate.

Tuttavia, la ricchezza dei dati comportamentali ad alta risoluzione permette di superare tale limite attraverso l'identificazione di *proxy* causali. In letteratura, variabili quali l'engagement, la *turn-taking* e la coordinazione motoria sono considerate precursori fondamentali del progresso terapeutico. In questo lavoro, si è scelto di focalizzare l'analisi sulla **joint attention**, parametro critico nei protocolli ABA per l'autismo.

La metrica **AttentionScore** è stata sviluppata seguendo le evidenze tecniche fornite da Cai et al. [3], i quali suggeriscono che l'integrazione della posa della testa e della direzione dello sguardo tramite sensori ottici permetta una descrizione digitale accurata dell'attenzione nei bambini con ASD.

3.3.1 Allineamento Vettoriale e Cosine Similarity

Il calcolo dell'indice **AttentionScore** segue tre fasi analitiche:

- **Normalizzazione Vettoriale:** I dati dello sguardo e della testa sono rappresentati da vettori (x, y, z) nello spazio 3D. Poiché a noi interessa solo

la direzione verso cui il bambino punta gli occhi o il volto, e non l'intensità del segnale catturato dal sensore, applichiamo la normalizzazione.

Questa operazione consiste nel dividere ogni vettore per la sua lunghezza (norma), trasformandolo in un **vettore unitario** con lunghezza pari a 1:

$$\hat{\mathbf{v}} = \frac{\mathbf{v}}{\|\mathbf{v}\|} \tag{2}$$

Questo passaggio ci permette innanzitutto di **eliminare il rumore**, rendendo il calcolo indipendete dalla distanze del bambino dalla telecamera o da variazioni di luminosità che potrebbero causare alterazioni al vettore. Inoltre, la normalizzazione ci garantisce un indice fisso che permette alla *Cosine Similarity* di restituire sempre un valore compreso tra -1 e 1.

- **Calcolo della Cosine Similarity:** Per ogni frame t, si stima l'allineamento angolare tramite prodotto scalare. Un valore $S_t = 1$ indica una perfetta convergenza tra sguardo e orientamento del capo:

$$S_t = \hat{\mathbf{v}}_{head} \cdot \hat{\mathbf{v}}_{eye} = \cos(\theta) \tag{3}$$

- **Aggregazione Temporale:** L'outcome finale della sessione è derivato dalla media aritmetica dei valori di similarità su tutti gli N frame validi:

$$AttentionScore = \frac{1}{N} \sum_{t=1}^{N} S_t \tag{4}$$

L'introduzione di questa metrica risponde alla necessità di sintetizzare flussi di dati complessi e ad alta frequenza in un unico indicatore numerico che rappresenti fedelmente il livello di *engagement* del bambino. In questo modo, l'intero comportamento visivo registrato durante una sessione viene condensato in un descrittore sintetico e robusto. Tale valore non solo facilita l'interpretazione clinica dell'attenzione visiva, ma si presta ad essere utilizzato direttamente come variabile target (outcome) all'interno dei modelli di inferenza causale, permettendo di misurare l'efficacia del trattamento robotico rispetto a quello umano.

Nota sui dati utilizzati: per il calcolo del proxy sono risultate valide 3049 sessioni su 3121, dopo la rimozione automatica di frame con valori mancanti o non numericamente stabili.

3.3.2 Interpretazione del proxy AttentionScore

L'AttentionScore così definito assume valori compresi nell'intervallo $[-1, 1]$. In questo contesto specifico:

- **Valori prossimi a 1:** Indicano una perfetta convergenza tra la direzione della testa e dello sguardo, suggerendo che il bambino è attivamente focalizzato sul target terapeutico.

- **Valori decrescenti:** Segnalano una divergenza tra l'orientamento del capo e lo sguardo effettivo, interpretabile come una riduzione dell'attenzione o una distrazione verso stimoli ambientali non pertinenti alla terapia.

3.3.3 Analisi descrittiva dell'AttentionScore

L'outcome *AttentionScore* è stato calcolato per le 3049 sessioni valide. L'analisi descrittiva a livello di bambino ha rivelato distribuzioni sovrapponibili tra i due gruppi:

- **Media Gruppo RET** ($n = 30$)**:** 0.92818.
- **Media Gruppo SHT** ($n = 31$)**:** 0.92876.

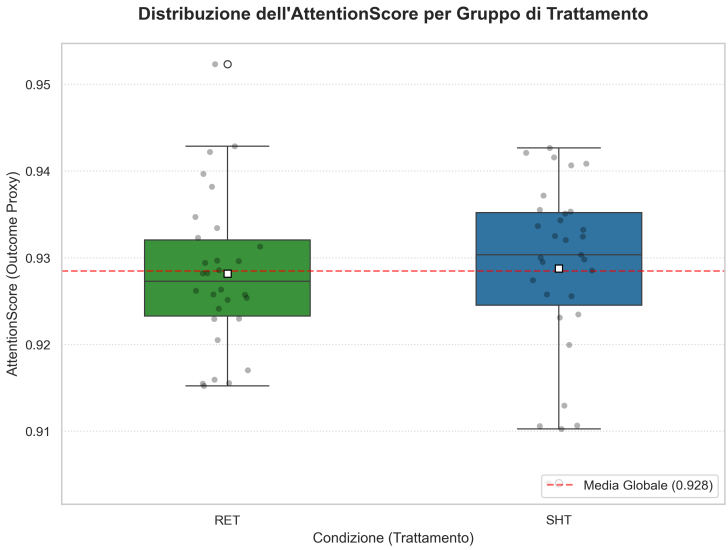

Figura 7: Distribuzione dell'outcome proxy AttentionScore per condizione di trattamento nel Dataset DREAM.

Per una valutazione preliminare dell'impatto della terapia robotica, è stata calcolata la differenza tra le medie dell'outcome nel gruppo di trattamento e in quello di controllo, definita come *Average Treatment Effect* (ATE) grezzo. Questo approccio descrittivo permette di osservare la magnitudo dell'effetto del robot sul proxy di *joint attention* senza ancora considerare il bilanciamento delle covariate.

Sulla base dei dati aggregati per bambino, sono state ottenute le seguenti stime:

- **ATE grezzo** ($\Delta\mu$)**:** -0.00058.

L'entità dell'ATE grezzo risulta trascurabile, suggerendo che, a un livello puramente descrittivo, l'intervento robotico e quello umano producano risposte di *engagement* visivo pressoché identiche.

3.3.4 Test di significatività statistica: Welch t-test

Per verificare se la differenza osservata sia statisticamente significativa o imputabile al caso, è stato applicato il **test t di Welch**.

L'ipotesi nulla del test afferma che non vi sia differenza sistematica tra le medie dei due gruppi ($\mu_{RET} = \mu_{SHT}$), ovvero che l'effetto medio del trattamento sia nullo. I risultati ottenuti sono i seguenti:

- **Statistica t:** -0.237.
- **Gradi di libertà (df):** 58.19.
- **p-value:** 0.813.

Dato che il $p-value$ è molto superiore alla soglia standard di 0.05, non vi è evidenza statistica sufficiente per respingere l'ipotesi nulla. Tale risultato conferma che, in questa fase preliminare e non bilanciata, non emerge un vantaggio differenziale significativo tra le due condizioni. Questo dato rafforza la necessità di passare a modelli di *Causal Inference* più sofisticati per isolare l'effetto del trattamento eliminando il possibile rumore introdotto dalle covariate individuali.

3.4 Limiti dei Modelli Classici e Necessità del Causal Deep Learning

I modelli statistici tradizionali presentano limiti strutturali nel catturare relazioni non lineari e interazioni multidimensionali tra le covariate X e l'outcome Y. Dato che i dati dei sensori sono 'sporchi' e influenzati da molti fattori esterni (età, gravità del bambino, rumore ambientale), non possiamo limitarci a fare una media aritmetica tra i due gruppo: bisogna usare tecniche più robuste. Il *Causal Deep Learning* supera queste criticità apprendendo rappresentazioni latenti che bilanciano i gruppi di trattamento e controllo, riducendo la discrepanza tra le distribuzioni ed estraendo feature predittive per la stima dei risultati potenziali.

3.4.1 L'architettura DragonNet

Sviluppata per affrontare il problema del bias di selezione, **DragonNet** si basa sul principio della *sufficienza del propensity score* [5]. L'architettura è composta da una struttura a tre "teste" che condividono i primi layer di rappresentazione:

- **Shared Layers:** Mappano le covariate originali (Età, ADOS, Genere) in una rappresentazione condivisa $\phi(X)$.
- **Propensity Head:** Utilizza $\phi(X)$ per predire la probabilità di trattamento $P(T = 1|X)$, forzando la rete a conservare informazioni rilevanti per l'assegnazione.

- **Outcome Heads (Y_0, Y_1):** Due rami indipendenti stimano i risultati potenziali.

Un elemento distintivo implementato è la **Targeted Regularization**. Questa tecnica accoppia la predizione dell'outcome con il propensity score, applicando una correzione statistica ispirata al TMLE (*Targeted Maximum Likelihood Estimation*) che ottimizza la rete direttamente per la stima dell'ATE.

3.4.2 Il Modello BCAUSS

Il modello **BCAUSS** (*Balanced Covariate Representation through Self-Supervised Learning*) introduce un paradigma innovativo per la gestione di piccoli campioni [6], come i 61 soggetti del dataset DREAM. A differenza di DragonNet, BCAUSS integra un compito di **Self-Supervised Learning** (SSL): la rete impara a ricostruire le covariate stesse come "pretext task". Questo processo di denoising garantisce che la rappresentazione $\phi(X)$ catturi la struttura intrinseca dei dati clinici, prevenendo l'overfitting e migliorando la robustezza della stima causale in scenari con alta varianza e campioni limitati.

3.4.3 Protocollo di Training e Strategia di Validazione

Il processo di addestramento è stato uniformato per entrambi i modelli al fine di garantire la comparabilità dei risultati e la riproducibilità dell'esperimento. La pipeline tecnica è stata strutturata come segue:

- **Normalizzazione:** Tutte le covariate sono state sottoposte a standardizzazione ($\mu = 0, \sigma = 1$) tramite *StandardScaler*. Questa operazione è fondamentale per uniformare la scala delle feature e stabilizzare la convergenza della discesa del gradiente.
- **Configurazione degli Iperparametri:** È stato adottato l'ottimizzatore *Adam* con un orizzonte di addestramento fissato a 100 epoche. Per massimizzare la precisione dell'inferenza, è stata attivata la *Targeted Regularization* in entrambi i modelli, forzando la rete a minimizzare il bias nella stima del parametro causale.
- **Analisi della Varianza e Stocasticità:** Data la natura non deterministica dell'inizializzazione delle reti neurali, è stata implementata una procedura di validazione multi-simulazione composta da 10 esecuzioni indipendenti.
- **Isolamento delle Iterazioni:** Ad ogni run, la sessione del backend (Keras/TensorFlow) è stata resettata sistematicamente (*K.clear_session()*). Questa procedura garantisce l'indipendenza dei pesi iniziali, permettendo di calcolare una distribuzione realistica dell'ATE e di valutarne la robustezza statistica attraverso la deviazione standard delle stime.

4 Risultati e discussioni

In questo capitolo vengono analizzati i risultati ottenuti dall'applicazione delle architetture di *Causal Deep Learning* sul dataset DREAM. L'obiettivo è valutare l'efficacia della *Robot-Enhanced Therapy* (RET) rispetto alla condizione di controllo (SHT), depurando la stima dai possibili fattori confondenti individuati nelle fasi precedenti attraverso l'uso di modelli neurali avanzati.

4.1 Confronto delle Stime ATE

La valutazione dell'effetto causale medio (*Average Treatment Effect*) è stata condotta confrontando le distribuzioni delle stime generate da **DragonNet** e **BCAUSS** attraverso 10 iterazioni indipendenti. I risultati statistici sono sintetizzati nella Tabella 2.

Tabella 2: Analisi comparativa delle stime ATE tra le architetture neurali.

Modello	**ATE Medio (μ)**	**Deviazione Std (σ)**	**Valore Min**	**Valore Max**
BCAUSS	-0.0168	0.0675	-0.1615	0.0841
DragonNet	-0.0306	0.0454	-0.0682	0.0891

Dall'analisi dei dati e della Figura 8, emergono due evidenze tecniche principali:

1. **Stabilità della Stima:** DragonNet presenta una deviazione standard inferiore ($\sigma = 0.045$), indicando una convergenza più coerente verso il valore centrale. BCAUSS mostra una varianza superiore ($\sigma = 0.067$), riflettendo la natura più complessa del bilanciamento tramite self-supervisione, pur mantenendo una media leggermente meno negativa (-0.016).
2. **Distribuzione delle Risposte:** Entrambi i modelli mostrano una distribuzione che interseca lo zero. La presenza di valori massimi positivi (circa +0.08 per entrambi i modelli) suggerisce che il trattamento produce benefici tangibili su una sottopolazione di soggetti, nonostante la media globale rimanga vicina alla neutralità statistica.

4.2 Interpretazione dei Risultati

L'interpretazione dei risultati richiede una prospettiva che integri il rigore statistico con le dinamiche cliniche del protocollo DREAM per bambini con ASD.

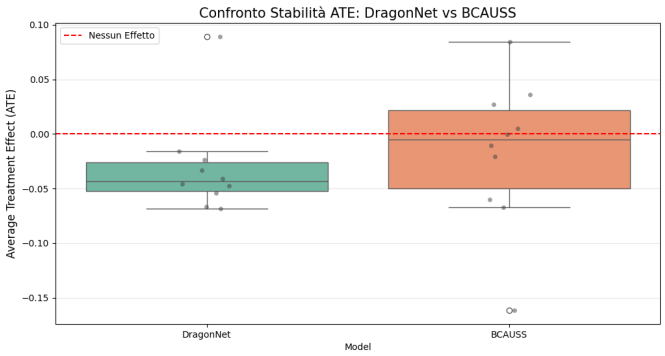

Figura 8: Distribuzione dell'ATE stimato per i modelli DragonNet e BCAUSS su 10 run indipendenti. La linea tratteggiata indica lo zero (assenza di effetto).

4.2.1 Analisi dell'Effetto Medio e Variabilità Individuale

L'ATE stimato prossimo allo zero indica che, a livello di popolazione totale ($N = 61$), non si registra una divergenza netta tra la terapia robotica e quella umana sul parametro **AttentionScore**. Questo fenomeno suggerisce che l'effetto della terapia con robot potrebbe non essere immediatamente superiore in termini assoluti durante la fase iniziale, ma agire come un catalizzatore che richiede un'esposizione prolungata o che risponde in modo estremamente differenziato tra i soggetti (*eterogeneità del trattamento*).

4.2.2 Resilienza ai Fattori Confondenti

Un risultato cruciale di questa fase è la capacità dei modelli di mantenere stime coerenti nonostante l'inclusione di covariate critiche come l'età, il genere ed il punteggio ADOS. L'attivazione della *Targeted Regularization* ha permesso di "isolare" l'effetto del trattamento RET, garantendo che i valori di ATE calcolati siano depurati dal bias di selezione intrinseco nelle assegnazioni cliniche originali.

5 Conclusioni e Sviluppi Futuri

Il cuore di questo progetto è stato rispondere a una domanda fondamentale: *"Cosa sarebbe successo agli stessi bambini se non avessero utilizzato i robot?"*. Poiché nella realtà non possiamo osservare contemporaneamente lo stesso bambino sia con che senza robot (il cosiddetto problema fondamentale dell'inferenza causale), abbiamo utilizzato il **Causal Deep Learning** per stimare questa quantità controffattuale.

5.1 Sintesi del Lavoro e Metodologia

Per rendere il confronto tra la terapia con robot (RET) e quella classica (SHT) il più equo possibile, abbiamo seguito un percorso rigoroso:

- abbiamo "pulito" i dati provenienti dai sensori per eliminare i disturbi esterni;
- abbiamo bilanciato le caratteristiche dei bambini (come età, gravità dell'autismo (ADOS) e genere) in modo che i due gruppi fossero realmente confrontabili;
- abbiamo costruito un proxy comportamentale di joint attention (AttentionScore) basato sulla cosine similarity tra eye-gaze e head-gaze;
- abbiamo utilizzato i modelli **DragonNet** e **BCAUSS** per simulare lo scenario controffattuale e isolare il puro effetto causale dell'intervento tecnologico.

5.2 Considerazioni sui Risultati

I nostri modelli indicano che l'effetto causale medio (ATE) del robot è paragonabile a quello del terapista umano. Questo risultato risponde al nostro obiettivo principale: l'uso di robot supervisionati causa miglioramenti nei risultati terapeutici (in termini di *AttentionScore*) che sono altrettanto validi rispetto alla terapia tradizionale. Il robot, quindi, non è solo uno strumento accessorio, ma un sostituto efficace che può affiancare il terapista mantenendo alti gli standard di cura.

5.3 Limiti e Prospettive Future

Nonostante la validità del metodo, i dati riguardano un campione limitato (61 bambini) e le sessioni iniziali della terapia. Per completare la risposta alla nostra domanda controffattuale, la ricerca futura si concentrerà su:

- **Personalizzazione (CATE):** Identificare quali caratteristiche specifiche di un bambino lo rendono più propenso a rispondere positivamente al robot.
- **Analisi nel tempo:** Verificare se l'effetto causale del robot rimane costante o aumenta con il passare delle settimane, superando il semplice "effetto novità".

Riferimenti bibliografici

[1] Pablo G. Esteban et al. "How to Build a Supervised Autonomous System for Robot-Enhanced Therapy for Children with Autism Spectrum Disorder". In: *Paladyn, Journal of Behavioral Robotics* 8.1 (2017), pp. 18–38. DOI: 10.1515/pjbr-2017-0002.

[2] Hoang-Long Cao et al. "Robot-Enhanced Therapy: Development and Validation of a Supervised Autonomous Robotic System for Autism Spectrum Disorders Therapy". In: *IEEE Robotics & Automation Magazine* 26.2 (2019), pp. 49–58. DOI: 10.1109/MRA.2019.2904121.

[3] Haibin Cai et al. "Sensing-Enhanced Therapy System for Assessing Children With Autism Spectrum Disorders: A Feasibility Study". In: *IEEE Sensors Journal* 19.4 (2019), pp. 1508–1517. DOI: 10.1109/JSEN.2018.2882515.

[4] Gianluca Argentin. *Inferenza causale e approccio controfattuale. In I. Pais, F. Barbera (a cura di), Fondamenti di sociologia economica (pp. 1-25). ITA : EGEA.* Disponibile online. 2017. URL: https://www.unisalento.it/documents/20152/14289466/Capitolo+15.pdf/cd527c8c-b1d0-842c-d026-b1b418ff4948?version=1.0&download=true.

[5] Claudia Shi, David M Blei e Victor Veitch. "Adapting Neural Networks for the Estimation of Treatment Effects". In: *Advances in Neural Information Processing Systems*. 2019.

[6] Gino Tesei et al. "Learning end-to-end patient representations through self-supervised covariate balancing for causal treatment effect estimation". In: *Journal of Biomedical Informatics* 140 (2023), p. 104339.